

무료 앱은 정말 무료인가? : Google Play App Data Safety 기반 개인정보 수집·공유와 데이터 수익화 신호 분석

소프트웨어융합학과 3학년 김현정

학번: 2024105245

초 록 (abstract)

대다수의 사용자는 무료 앱이 어떤 데이터를 수집하고 어떻게 수익화하는지 인지하지 못한 채 서비스를 이용한다. 본 연구는 Google Play Store의 Data Safety 공시 데이터와 OS 레벨 권한 요청을 통합 분석하여, 무료 앱의 데이터 수집·공유 구조와 수익화 연관성을 실증하는 것을 목적으로 한다. 이를 위해 1,562개 앱을 수집·구성하고 Mann-Whitney U 검정, Negative Binomial Regression, Random Forest 분류 등을 활용하여 세 가지 가설을 검증하였다. 분석 결과, 무료 앱은 유료 앱보다 데이터 수집 범위가 단순 비교 기준 4.2배, 교란 변수 통제 후에도 2.12배 넓고, 공유 데이터 항목 중 79.4%가 하나 이상의 수익화 목적과 결합되어 있으며, 수집·공유 특성만으로 고위험 앱을 ROC-AUC 0.972 수준에서 식별할 수 있음이 확인되었다. 분석 결과의 실용적 적용을 위해 Google Play Store 페이지에서 고위험 앱 여부를 자동으로 탐지하는 크롬 확장 프로그램도 개발하였다. 본 연구는 무료 앱의 '0원'이라는 가격 뒤에 데이터 수집이라는 실질적 비용이 존재함을 데이터로 실증한다.

1. 서 론 (약 1p)

현대에 들어 스마트폰 보급의 확산과 함께 모바일 앱 시장이 급속도로 성장하면서, 대다수의 앱이 '무료'로 제공되고 있다. 2024년 기준 전체 앱 다운로드의 98% 이상이 무료 앱에서 발생하며, 무료 앱이 창출하는 수익은 약 9,350억 달러에 달한다[1]. 직접적인 판매 수익 없이 이처럼 거대한 경제 규모가 유지될 수 있는 것은, 무료 앱의 주요 수익 모델이 사용자 데이터를 활용한 광고·개인화·분석 서비스이기 때문이다. Zuboff[2]가 '감시 자본주의'로 명명한 이 구조에서 사용자는 금전적 비용 대신 자신의 개인 데이터로 서비스 대가를 지불한다고 볼 수 있다.

그러나 대다수의 사용자는 이러한 구조를 인지하지 못한 채 서비스를 이용한다. 쿠팡, 무신사 등 국내 주요 플랫폼에서 개인정보 유출 사건이 반복적으로 발생하는 상황에서[3], 사용자 인식 격차는 실증적으로도 확인된다. Pew Research Center(2023)에 따르면 미국 성인의 67%가 기업이 자신의 데이터로 무엇을 하는지 이해하지 못한다고 응답했으며, 이 수치는 2019년(59%) 대비 증가한 것이다[4]. 특히 Ofcom 기반 연구에서는 검색 사용자의 64%가 고유 식별자 수집 자체를 인지하지 못하고 있어[5], 우려와 이해 사이의 괴리가 구조적으로 심화되고 있음을 알 수 있다. 앱이 어떤 데이터를 얼마나 수집하고 그것이 어떤 목적으로 활용되는지 사용자가 사전에 파악하기란 쉽지 않다. 구글은 2022년부터 Google Play Store에 'Data Safety' 섹션을 도입하여 개발자가 수집·공유 항목과 그 목적을 공시하도록 의무화하였으나[6], 개발자 자기신고

방식으로 운영되어 실제 수집 범위가 과소 공시될 가능성이 있다.

이러한 문제를 해결하기 위한 기존 연구들은 무료 앱이 유료 앱보다 더 많은 OS 권한을 요청한다는 사실을 정적분석으로 확인하였으나[7, 8], 두 가지 한계가 존재한다. 첫째, Data Safety 공시 데이터와 OS 권한 데이터를 결합한 통합 분석이 부족하다. 둘째, 수집 규모는 다루되 수집된 데이터가 실제로 어떤 목적과 결합되는지, 그리고 이를 기반으로 고위험 앱을 사전에 식별할 수 있는지에 대한 분석은 충분히 이루어지지 않았다.

본 연구는 이러한 공백을 메우고자 Google Play Store의 Data Safety 공시 데이터와 OS 레벨 권한 요청 데이터를 통합하여 다음 세 가지 가설을 설정하고 검증한다.

- **가설 1** : 무료 앱은 유료 앱보다 데이터 수집 범위가 더 넓을 것이다.
- **가설 2** : 무료 앱이 공유하는 데이터는 앱 기능 제공 목적보다 수익화 목적과 결합되는 비율이 더 높을 것이다.
- **가설 3** : Data Safety 기반 데이터 수집·공유 특성은 고위험 앱 여부를 유의미하게 구분할 수 있을 것이다.

이를 위해 1,562개 앱을 수집·구성하고 Mann-Whitney U 검정·Cliff's δ ·Negative Binomial Regression·Random Forest 분류 등을 순차적으로 적용하였다. 세 가설이 모두 지지됨으로써, 무료 앱 사용자가 실질적으로 데이터를

비용으로 지불하고 있음을 실증하고, Data Safety 공시 정보 기반 고위험 앱 사전 탐지의 가능성을 제시한다.

2. 관련 연구 (약 0.5~1p)

2.1 무료 앱의 데이터 수집과 권한 요청 연구

무료 앱의 데이터 수집 범위가 유료 앱보다 넓다는 사실을 실증한 연구들이 수행되었다. Alkinoon et al.[7]은 49,578개 앱을 대상으로 Google Play Data Safety 섹션과 권한 데이터를 분석하여, 무료 앱이 유료 앱보다 더 넓은 권한 범위를 신고하며 전체 앱의 25.44%가 Data Safety 섹션을 미완성 상태로 두고 있음을 확인하였다. SafetyDetectives[8]의 보고서에 따르면 무료 앱은 유료 앱보다 데이터를 수집할 가능성이 4배 높은 것으로 나타났으며, 마케팅·거래 목적의 불필요한 권한을 과잉 요청하는 경향이 확인되었다. 그러나 이들 연구는 수집된 데이터가 실제로 어떤 목적과 결합되는지는 분석하지 않았다는 한계가 있다.

2.2 데이터 수익화 구조와 감시 자본주의

무료 앱의 수익 구조를 이론적으로 설명한 연구도 존재한다. Zuboff[2]는 감시 자본주의 개념을 통해 무료 디지털 서비스가 사용자 행동 데이터를 예측 상품으로 전환하여 광고 시장에 판매하는 구조를 이론화하였다. 실제로 2024년 기준 전 세계 모바일 광고 지출은 약 4,000억 달러에 달하며[9], 전체 앱 수익의 대부분이 광고·데이터 기반 수익화에서 창출된다. 그러나 이러한 연구들은 수익화 구조를 거시적 관점에서 이론화하는 데 그치며, 개별 앱 단위에서 수집·공유 데이터가 실제로 수익화 목적과 어떻게 결합되는지를 데이터로 실증하지 않았다는 한계가 있다.

2.3 기존 연구의 한계와 본 연구의 차별점

기존 연구들은 무료 앱이 더 많은 데이터를 수집한다는 사실과 그 배경에 수익화 구조가 존재한다는 점을 각각 보여주었으나, 두 관점을 연결한 통합적 분석은 이루어지지 않았다. 본 연구는 Data Safety 공시와 OS 권한 데이터를 합집합으로 통합(unified_data_scope)하여 과소 측정 문제를 보완하고, 수집·공유 데이터의 목적별 구조를 실증적으로 분석하며, 나아가 Random Forest 기반 고위험 앱 분류 모델을 제시한다는 점에서 기존 연구와 차별화된다. 나아가 분석 결과의 실용적 적용 측면에서도 기존 도구와의 차이가 존재하며, 이는 다음 절에서 다룬다.

2.4 앱 설치 전 프라이버시 위험 예측 도구의 부재

웹 생태계에서는 Ghostery[10], DuckDuckGo Privacy Essentials[11] 등 실시간 트래커 감시 도구가 보급되어 있으나, 모바일 앱 생태계는 샌드박스 구조 특성상 설치 전 데이터 수집 행위를 외부에서 감시하기 어렵다. 유사 목적의 도구로 Exodify[12](트래커 SDK 정적 분석)와

Chrome-Stats[13](메타 데이터 기반 휴리스틱)가 존재하나, 두 도구 모두 Data Safety 공시를 파싱하지 않으며 수익화 목적 결합 구조를 분석하지 않는다. 즉, 앱 설치 전 데이터 수익화 구조를 근거로 위험도를 판단하는 도구는 현재까지 확인되지 않으며, 본 연구의 크롬 확장 프로그램은 이 공백을 메운다.

3. 본론 (약 3p)

본 연구는 Google Play Store에서 수집한 1,562개 앱 데이터를 활용한다. 데이터는 google-play-scraper 라이브러리를 통해 앱별 Data Safety 공시 정보(dataSafetyRaw), OS 레벨 권한 요청(permissionsRaw), 수익화 구조 변수(free, adSupported, offersIAP, price), 인기도 변수(minInstalls, score, ratings)를 수집하였다. 핵심 종속변수인 unified_data_scope는 Data Safety 수집 카테고리 OS 권한 카테고리의 합집합으로 산출하였다. 이는 개발자 자기신고 방식인 Data Safety만으로는 실제 수집 범위가 과소 측정될 수 있기 때문으로, 두 데이터를 통합함으로써 보완하였다. 결측값 처리는 분석의 핵심 변수(free, adSupported, offersIAP 등) 결측 5건만 제거하고, score·reviews·ratings 결측 50건은 핵심 변수와 무관하여 유지하였다.


[표1 주요 분석 변수 설명]

변수명	설명
collected_data_count	수집 데이터 항목 수
shared_data_count	공유 데이터 항목 수
total_data_scope	수집 + 공유 합산
sensitive_data_count	민감 데이터 항목 수
data_risk_score	수익화 목적 결합 항목 수 (가설2·가설3 핵심 변수)
permission_count	OS 레벨 권한 요청 카테고리 수
unified_data_scope	Data Safety 신고 카테고리 ∪ 권한 기반 카테고리 (가설1 핵심 종속변수)

3.1. 가설 1: 무료 앱은 유료 앱보다 데이터 수집 범위가 더 넓을 것이다

가설 1을 검증하기 위해 기술통계 비교, Mann-Whitney U 검정, Cliff's δ 효과 크기 분석, Negative Binomial Regression을 순차적으로 수행하였다. 종속변수는 Data Safety 신고 항목과 OS 레벨 권한 요청을 합집합으로 통합한 데이터 수집 카테고리 수(unified_data_scope)이며, 앱 카테고리·설치 수·광고 여부·인앱구매 여부를 교란 변수로 통제하였다.

기술통계 분석 결과, 무료 앱의 평균 수집 카테고리 수는 11.89개로 유료 앱(2.85개)의 약 4.2배에 달하였으며, 중앙값 기준으로도 무료 앱(11.0개)이 유료 앱(2.0개)보다 5.5배 높게 나타났다.



[그림1 무료 VS 유료 데이터 수집 범위 분포]


종속변수가 오른쪽으로 심하게 치우친 카운트 데이터이므로 Shapiro-Wilk 검정으로 정규성을 확인한 결과, 무료 앱($W = 0.9663$, $p = 2.88e-15$)과 유료 앱($W = 0.8254$, $p = 3.91e-22$) 모두 유의수준 0.001에서 정규성 가정이 기각되었으므로 비모수 검정인 Mann-Whitney U 검정을 적용하였다. p -value = $1.67e-129$ 로 유의수준 0.001보다 매우 작아 두 그룹 간 수집 범위 차이는 통계적으로 명확하게 유의미하였다. 대규모 표본에서 발생할 수 있는 과도한 유의성 문제를 보완하기 위해 Cliff's δ 를 함께 산출한 결과 $\delta = 0.7717$ 로, 무료 앱이 유료 앱보다 수집 카테고리가 더 많을 확률이 약 88.6%에 달하는 큰 효과(large)에 해당하였다.

마지막으로 교란 변수를 통제한 Negative Binomial Regression에서도 $IRR = 2.12$ ($p < 0.001$)로, 카테고리·설치 수·광고·인앱구매 여부를 모두 통제한 후에도 무료 앱의 수집 범위가 유료 앱보다 약 2.12배 넓게 나타났다. 이는 무료 앱의 광범위한 데이터 수집이 특정 카테고리나 인기도의 영향이 아닌, 무료라는 수익 구조 자체에서 비롯된 구조적 특성임을 의미한다. 따라서 가설 1은 지지된다.

3.2. 가설 2: 무료 앱의 데이터 사용은 수익화 목적과 함께 나타나는 비율이 높을 것이다.

가설 2에서는 분석 단위를 앱 단위가 아닌 Data Safety에 공개된 데이터 항목 단위로 설정하였다. 수익화 목적은 광고·마케팅(Advertising or marketing), 분석(Analytics), 개인화(Personalization)로 정의하였으며, 앱 기능 제공(App functionality)과의 결합 비율을 비교하였다. 분석 대상은 무료 앱의 공유 데이터(sharedData)로 한정하였는데, 이는 공유가 수익화가 일어나는 지점에 가장 가깝기 때문에, 즉 데이터가 광고 네트워크·분석 플랫폼 등 제3자에게 넘겨지는 행위이기 때문이다. 동일 앱 내 항목들이 서로 독립이 아닌 점을 고려하여 앱 단위 클러스터 부트스트랩 방식으로 95% 신뢰구간을 산출하였다.

분석 결과, 무료 앱이 제3자와 공유하는 데이터의 수익화 목적 결합 비율은 79.4%로, 앱 기능 제공 목적(40.0%)보다 약 39%p 높게 나타났다. 각 데이터 항목은 복수의 목적을 동시에 가질 수 있어 비율의 합은 100%를 초과할 수 있다. 95% 클러스터 부트스트랩 신뢰구간 역시 앱 기능 제공(37.3%~42.8%)과 수익화(77.3%~81.5%)가 전혀 겹치지 않아, 이 차이는 표본 오차에 의한 우연이 아닌 구조적 차이로 볼 수 있다.




[그림2 App functionality vs Monetization 비율]

이는 무료 앱 사용자가 앱을 무료로 사용하는 대신, 자신의 데이터를 광고·분석 생태계에 제공하는 구조에 놓여 있음을 의미한다. 따라서 가설 2는 지지된다.

3.3. 가설 3: 데이터 수집·공유 특성은 고위험 앱 여부를 유의미하게 구분할 수 있을 것이다

가설 3에서는 수익화 목적과 결합된 데이터 항목 수를 data_risk_score로 정의하고, 최적 군집 수 결정을 위해 Elbow Method와 Silhouette Score를 함께 적용하였다. 분석 결과 $k=2$ 일 때 Silhouette Score가 0.556으로 최대값을 기록하였고, Elbow Method에서도 $k=2 \rightarrow 3$ 구간의 Inertia 감소폭이 가장 크게 나타나 두 기준이 모두 $k=2$ 를 지목하였다. 이에 최적 군집 수를 2로 결정하였다.




[그림3 Elbow Method & Silhouette Score]

KMeans 군집화(k=2) 결과, data_risk_score 평균이 높은 군집에 속하는 558개 앱을 고위험 앱(high_risk = 1), 나머지 1,004개를 저위험 앱(high_risk = 0)으로 분류하였다. 군집 분석 결과 고위험 군집의 unified_data_scope 평균은 17.48로 나타나, 실제 적용 가능성을 고려하여 평균값에 근접한 정수 기준인 17을 임계값으로 설정하였다(unified_data_scope ≥ 17).


고위험 앱 식별을 위한 입력 변수로는 통합 수집 범위(unified_data_scope), 무료 여부, 광고 포함 여부, 인앱구매 여부, 설치 수(로그 변환), 앱 카테고리(원핫인코딩)를 사용하였으며, 고위험(558개)과 저위험(1,004개) 간 클래스 불균형을 보정하기 위해 class_weight='balanced'를 적용한 Random Forest 분류 모델을 학습시켰다.

지표	Accur acy	Precision	Recall	F1	ROC-AU C
결과	0.913 7	0.9048	0.848 2	0.875 6	0.9720

분석 결과 ROC-AUC 0.972, F1 0.876을 달성하였으며, 5-Fold 교차검증에서도 ROC-AUC 0.977 ± 0.007로 과적합 없이 안정적인 성능이 유지되었다.



[그림5 RF-변수 중요도 순위]




[그림4 RF-Confusion Matrix]

[표2 RF-분류 성능 지표]

변수 중요도 분석에서는 통합 수집 범위(unified_data_scope)가 전체 중요도의 62.2%를 차지하며 고위험 앱 분류에 압도적으로 기여하였다. 이는 앱이 얼마나 넓은 범위의 데이터에 접근하는지가 고위험 여부를 결정하는 핵심 요인임을 의미한다. 설치 수(14.9%)가 그 다음으로 높아 대형 앱일수록 데이터 수집 범위가 넓은 경향을 반영한다. 반면 무료 여부(9.5%), 광고 포함(1.8%), 인앱구매(1.5%)는 상대적으로 낮아, 수익화 모델 자체보다 실제 데이터 수집 범위가 위험도를 더 직접적으로 결정함을 보여준다.


따라서 가설 3은 지지된다. 이 결과는 사용자가 앱을 설치하기 전 Data Safety 정보와 권한 요청만으로도 해당 앱의 데이터 위험 수준을 유의미하게 판단할 수 있음을 시사한다.

이를 실용적으로 구현하기 위해 본 연구에서는 학습된 Random Forest 모델의 핵심 로직을 기반으로, Google Play Store 앱 페이지에서 Data Safety 정보를 자동으로 파싱하여 고위험 여부를 탐지하는 크롬 확장 프로그램을 개발하였다.



[그림6 크롬_고위험앱]

[그림6]는 통합 수집 범위가 임계값(17개) 이상인 고위험 앱에서 확장 프로그램이 경고를 표시하는 화면이며,



[그림7 크롬_저위험앱]

[그림7]는 수집 범위가 임계값 미만인 저위험 앱에서 안전 판정을 표시하는 화면이다. 사용자는 앱 설치 전 해당 페이지에서 데이터 위험 수준을 직접 확인할 수 있다.

4. 결론 (약 0.5p: 5페이지 안에 결론까지 끝내야함)

본 연구는 Google Play Store의 Data Safety 및 OS 레벨 권한 데이터 수집한 1,562개 앱을 대상으로, 무료 앱의 데이터 수집·공유 구조와 수익화 연관성을 세 가지 가설로 검증하였다. 가설 1에서는 단순 비교 기준 약 4.2배, 교란 변수를 통제된 후에도 무료 앱이 유료 앱보다 데이터 수집 범위가 약 2.12배 넓음을 확인하였고, 가설 2에서는 무료 앱이 제3자와 공유하는 데이터의 79.4%가 광고·분석·개인화 등 수익화 목적과 결합되어 있음을 확인하였으며, 가설 3에서는 이러한 수집·공유 특성만으로 고위험 앱을 ROC-AUC 0.972 수준에서 식별할 수 있음을 확인하였다. 이는 사용자가 인지하지 못한 사이 개인정보가 경제적 자원으로 활용되고 있음을 데이터로 실증한 결과이다.

세 가설의 결과는 하나의 일관된 흐름으로 연결된다. 무료 앱은 유료 앱보다 더 많은 데이터를 수집하고, 그 데이터의 대부분을 수익화 목적으로 제3자에게 공유하며, 이러한 수집·공유 구조는 머신러닝 모델로 사전에 탐지 가능하다. 즉, 무료 앱은 금전적 비용 대신 사용자의 데이터를 대가로 제공되는 서비스이며, 이는 Data Safety 공시와 OS 레벨 권한 데이터를 통합 분석함으로써 실증적으로 확인된다.

본 연구의 핵심 인사이트는 데이터 위험이 사후에 유출 사고로 드러나기 전에, 앱 설치 전 공개된 정보만으로도 위험 수준을 사전에 가능할 수 있다는 점이다. 이를 크롬 확장 프로그램으로 구현하여 사용자가 앱 설치 전 위험도를 직접 확인할 수 있도록 한 것은, 복잡한 데이터 분석 없이도 누구나 개인정보 위험을 인지하고 스스로 판단할 수 있는 환경을 만든다는 점에서 의의가 있다.

다만 본 연구는 몇 가지 한계를 지닌다.

첫째, Data Safety 공시가 개발자 자기신고 방식에 의존하므로 실제 수집·공유 범위가 과소 측정될 수 있다. 수집 범위는 OS 레벨 권한 데이터를 합집합으로 보완하였으나, 공유 범위는 여전히 자기신고에만 의존하여 공유 항목 0건이 실제 미공유인지 신고 누락인지 판별할 수 없다.

둘째, Analytics와 Personalization을 수익화 목적으로 분류하였으나 이 두 목적이 반드시 수익화와 직결된다고 단정할 수 없어, 가설 2의 수익화 비율은 실제보다 다소 과대 추정될 가능성이 있다. 향후 네트워크 트래픽 분석이나 동적 앱 실행 환경을 결합하면 실제 제3자 전송 여부를 직접 검증하여 이러한 한계를 보완할 수 있을 것이다.

5. 참고 문헌 (5페이지 제한에 포함되지 않음. 참고문헌은 많아도 상관없음)

- [1] Statista. "Revenue of mobile apps worldwide from 2014 to 2024." Statista, 2024.
- [2] S. Zuboff. The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power. PublicAffairs, 2019.
- [3] 개인정보보호위원회. 「2024 개인정보 이슈 심층 분석 보고서」. 개인정보보호위원회, 2024.
- [4] Pew Research Center. "How Americans View Data Privacy." October 2023. <https://www.pewresearch.org/internet/2023/10/18/how-americans-view-data-privacy/>
- [5] Information Commissioner's Office (ICO) and Ofcom. "Adtech Market Research Report." March 2019. <https://ico.org.uk/media2/migrated/2614568/ico-ofcom-adtech-research-20190320.pdf>

[6] Google Play Help. "Provide information for Google Play's Data safety section." Google, 2026.
<https://support.google.com/googleplay/android-developer/answer/10787469?hl=ko>

[7] A. Alkinoon, T.C. Dang, A. Alghuried, A. Alghamdi, S. Choi, M. Mohaisen, A. Wang, S. Salem, D. Mohaisen. "Mobile App Privacy Disclosures on Google Play in the Post-GDPR Context: A Large-Scale Analysis of Data Safety Section and Permissions." Information, Vol.17, No.4, 343, 2026.

[8] SafetyDetectives. "Free Apps, Hidden Costs: Unmasking the Privacy Risks Behind App Permissions." 2024.
<https://www.safetydetectives.com/blog/free-apps-permissions-study/>

[9] Business of Apps. "Mobile Advertising Rates (2025)." 2025.
<https://www.businessofapps.com/ads/research/mobile-app-advertising-cpm-rates/>

[10] Ghostery. "Ghostery Privacy Browser Extension." <https://www.ghostery.com>, 2024.

[11] DuckDuckGo. "DuckDuckGo Privacy Essentials." <https://duckduckgo.com/duckduckgo-help-pages/desktop/adding-duckduckgo-extension-to-your-browser/>, 2024.

[12] Exodus Privacy. "Exodify - Chrome/Firefox Extension powered by Exodus Privacy." <https://github.com/Exodus-Privacy/exodus>, 2018.

[13] Chrome-Stats. "Chrome-Stats Extension & App Analyzer." <https://chrome-stats.com>, 2024.

[14] 김현정. "App Risk Scanner - Google Play Store 고위험 앱 탐지 크롬 확장 프로그램."

<https://chromewebstore.google.com/detail/app-risk-scanner/hdbgjecbgikgjiddginklofbeemkhmj?hl=ko>, 2026.